Global Solution 2026.2

Machine Learning & Modelling

Alerta Criadouro

Matheus Rebelo - RM 570260

Felipe Olmos - RM 570946

Luiz Guilherme - RM 573486

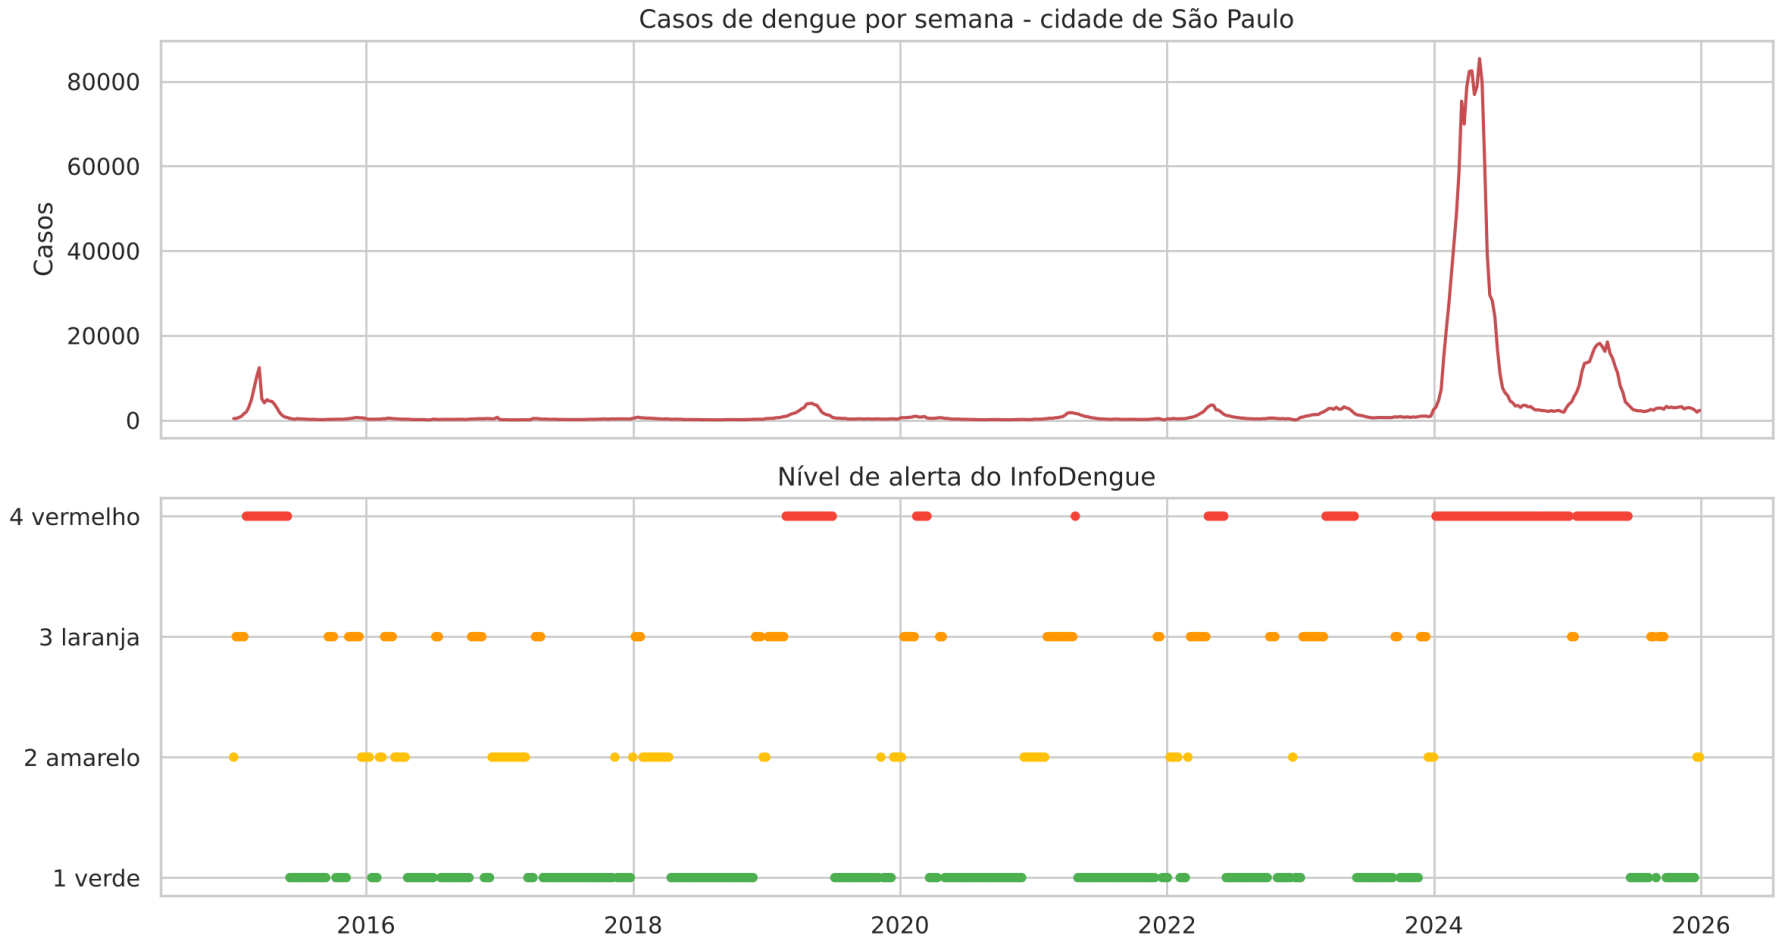
O problema e o público

- **75% dos focos** do mosquito da dengue ficam dentro das casas (governo de SP, via Poder360, fev/2026).
- **2024, o pior ano da história:** 6,48 milhões de casos prováveis e 5.972 mortes no Brasil. Só na cidade de São Paulo, mais de 1,2 milhão de casos notificados.
- **A larva vira mosquito em ~10 dias** e a família só percebe quando alguém adoece.
- **Público:** famílias que moram em casas com quintal em bairros da cidade de São Paulo.

Motivação: onde entra o Machine Learning

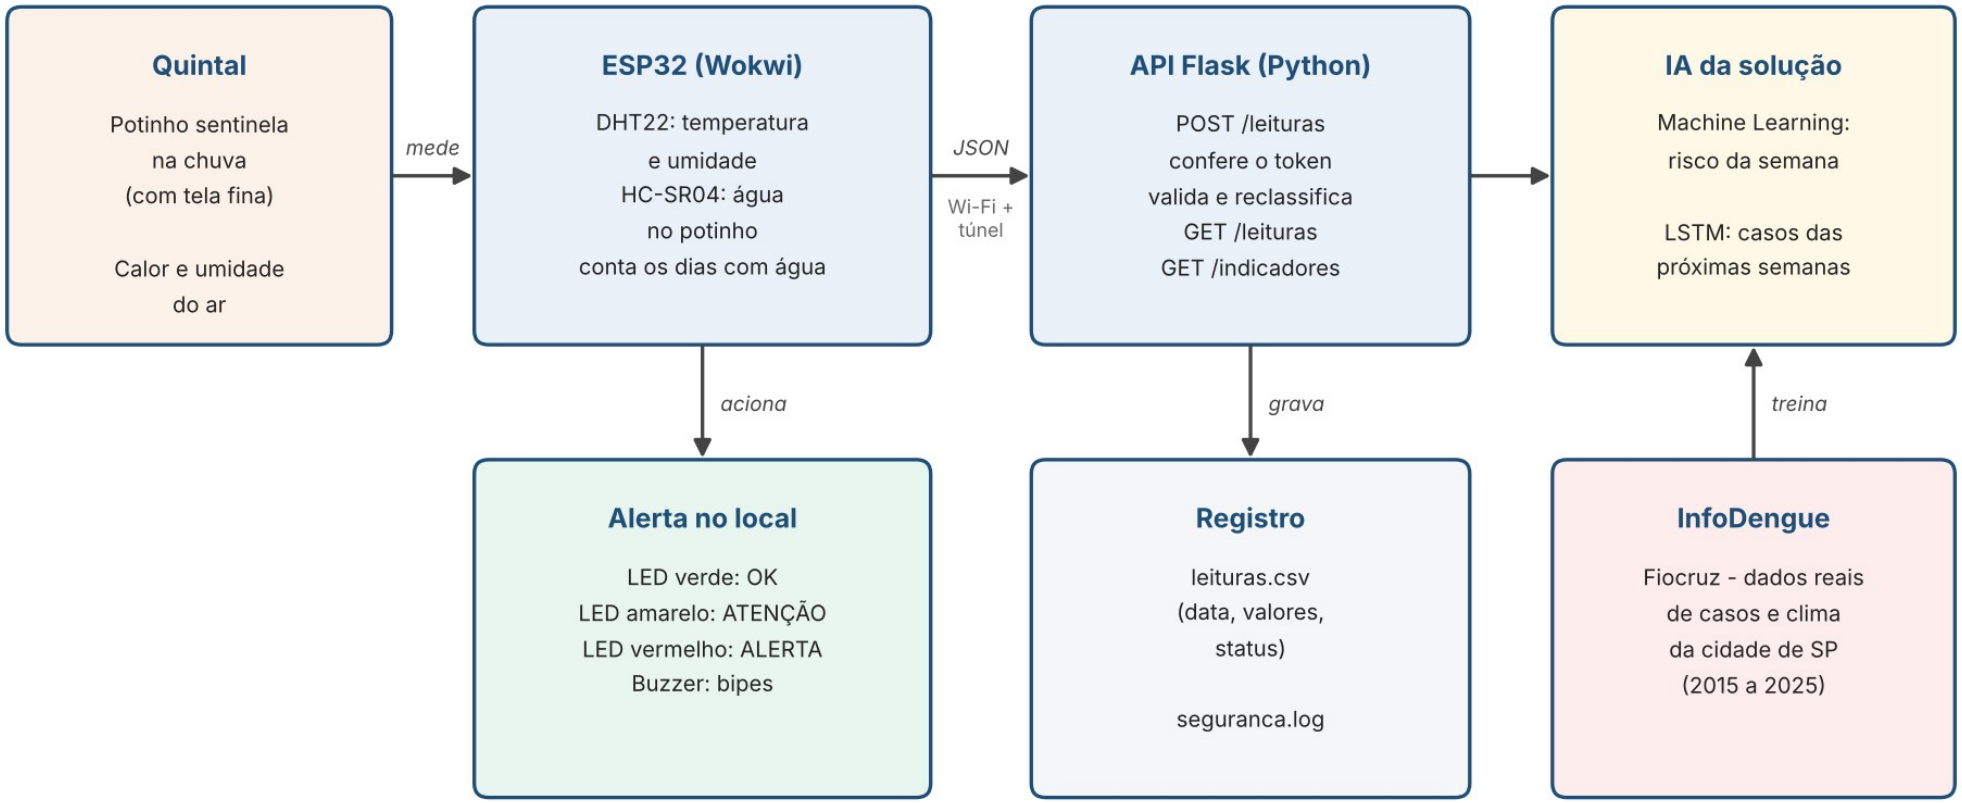
- **O Alerta Criadouro** é um aparelho com ESP32 que vê se o potinho sentinela do quintal está com água parada há dias.
- **Mas ele não sabe** como está a dengue na cidade.
- **Pergunta do modelo:** a próxima semana vai ser de risco alto (nível laranja ou vermelho do InfoDengue)?
- **Uso prático:** nas semanas perigosas o aviso fica mais firme e chega antes. Água no potinho + risco alto = vistoria hoje.

Base de dados: InfoDengue (Fiocruz e FGV)



574 semanas reais de São Paulo (2015-2025): casos, Rt, nível de alerta, temperatura e umidade. Hash SHA-256 conferido antes do treino.

Arquitetura simplificada



O modelo treina com o InfoDengue e devolve a probabilidade de risco alto para o aparelho e o app da família

Pré-processamento sem data leakage

- **Alvo da semana seguinte:** o nível do InfoDengue vem dos casos da semana. Usar esses casos para prever a mesma semana seria colar.
- **Divisão por tempo:** treino 2015-2022 (415 semanas) e teste 2023-2025 (156 semanas, com a epidemia de 2024).
- **Pipeline:** mediana para os valores faltando + StandardScaler + modelo. Tudo aprende só com o treino.
- **Atributos (18):** casos em log e defasados, variação, Rt, incidência, nível atual, clima da semana e média de 4 semanas, semana do ano (seno e cosseno).

Modelos comparados (teste 2023-2025, antes do tuning)

Modelo	F1 treino	F1 teste	Acurácia	Precisão	Recall
Baseline: classe mais comum	-	0,000	0,314	0,000	0,000
Baseline: persistência	0,867	0,944	0,923	0,944	0,944
Regressão Logística	0,906	0,886	0,827	0,808	0,981
Random Forest	0,979	0,945	0,923	0,928	0,963
XGBoost	1,000	0,954	0,936	0,945	0,963

A persistência (repetir o nível atual) é um baseline forte. O XGBoost com 100% no treino estava decorando: precisava de tuning.

Tuning de hiperparâmetros

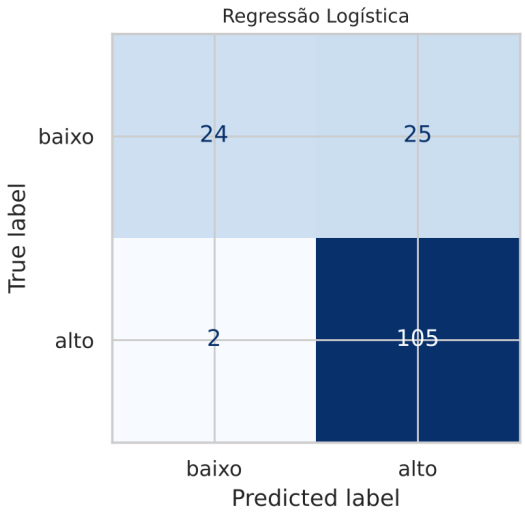
- **GridSearchCV + TimeSeriesSplit (5 dobras):** cada dobra treina com o passado e valida com o período seguinte, como no uso real.
- **Métrica: F1,** para equilibrar não perder semanas de risco e não dar alarme falso demais.
- **Random Forest:** max_depth 5, max_features 0,5, min_samples_leaf 3, 200 árvores · F1 na validação 0,885.
- **XGBoost:** max_depth 4, learning_rate 0,1, 300 árvores, subsample 1,0 · F1 na validação 0,911.

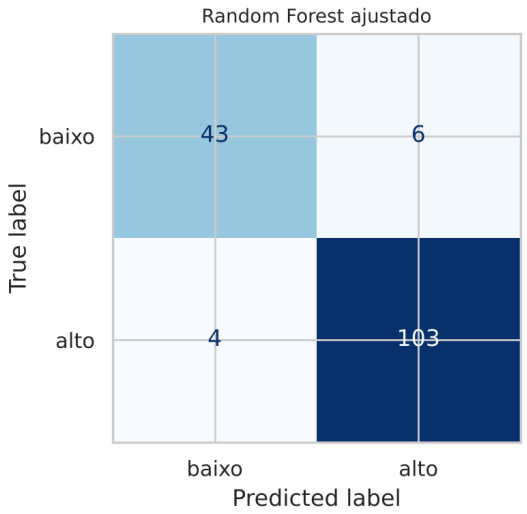
Métricas finais e generalização

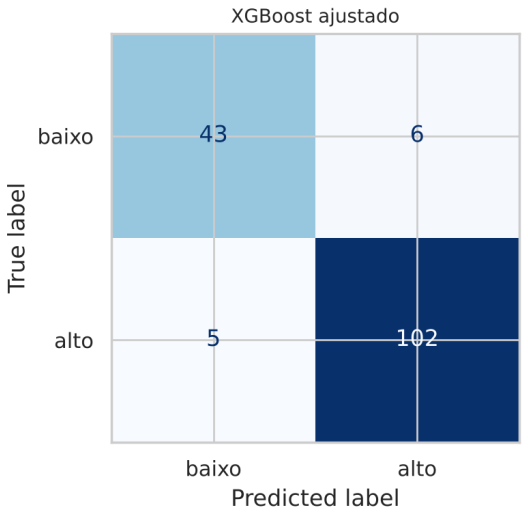
Modelo	F1 treino	F1 teste	Diferença	Acurácia	AUC
Regressão Logística	0,906	0,886	0,020	0,827	0,978
Random Forest ajustado	**0,967**	**0,954**	**0,013**	**0,936**	**0,965**
XGBoost ajustado	1,000	0,949	0,051	0,929	0,944
Baseline: persistência	0,867	0,944	-	0,923	-

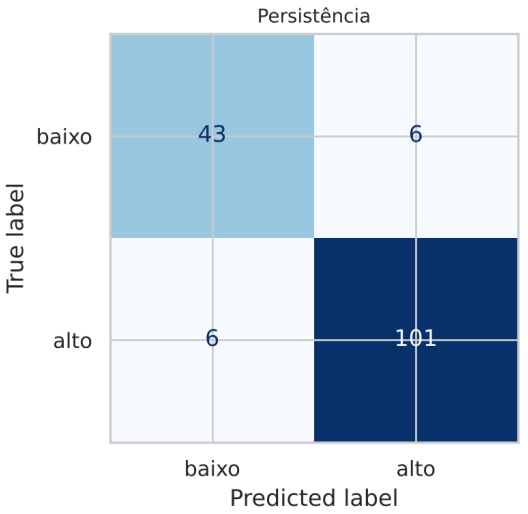
Modelo final: Random Forest ajustado. Maior F1 no teste, a menor diferença entre treino e teste (não decorou) e bate a persistência.

Matrizes de confusão no teste



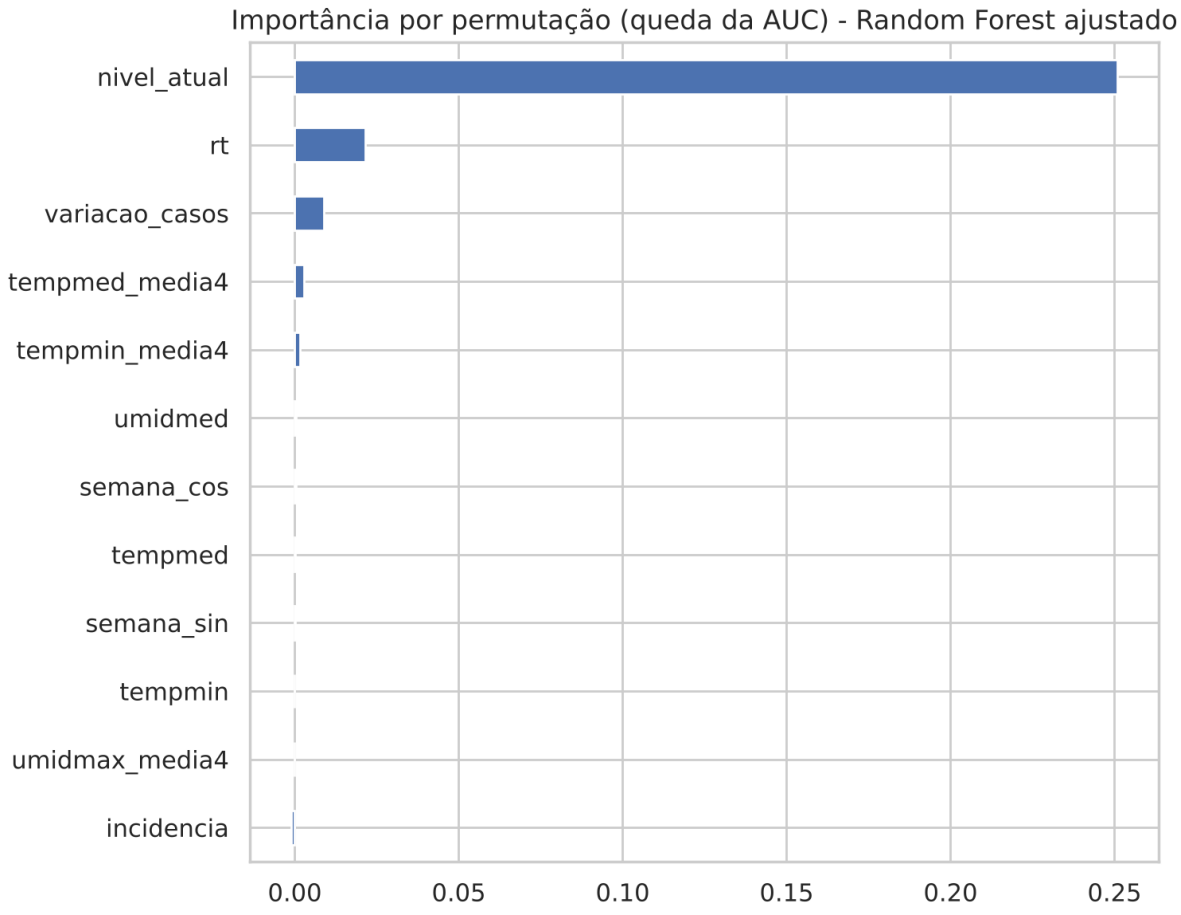


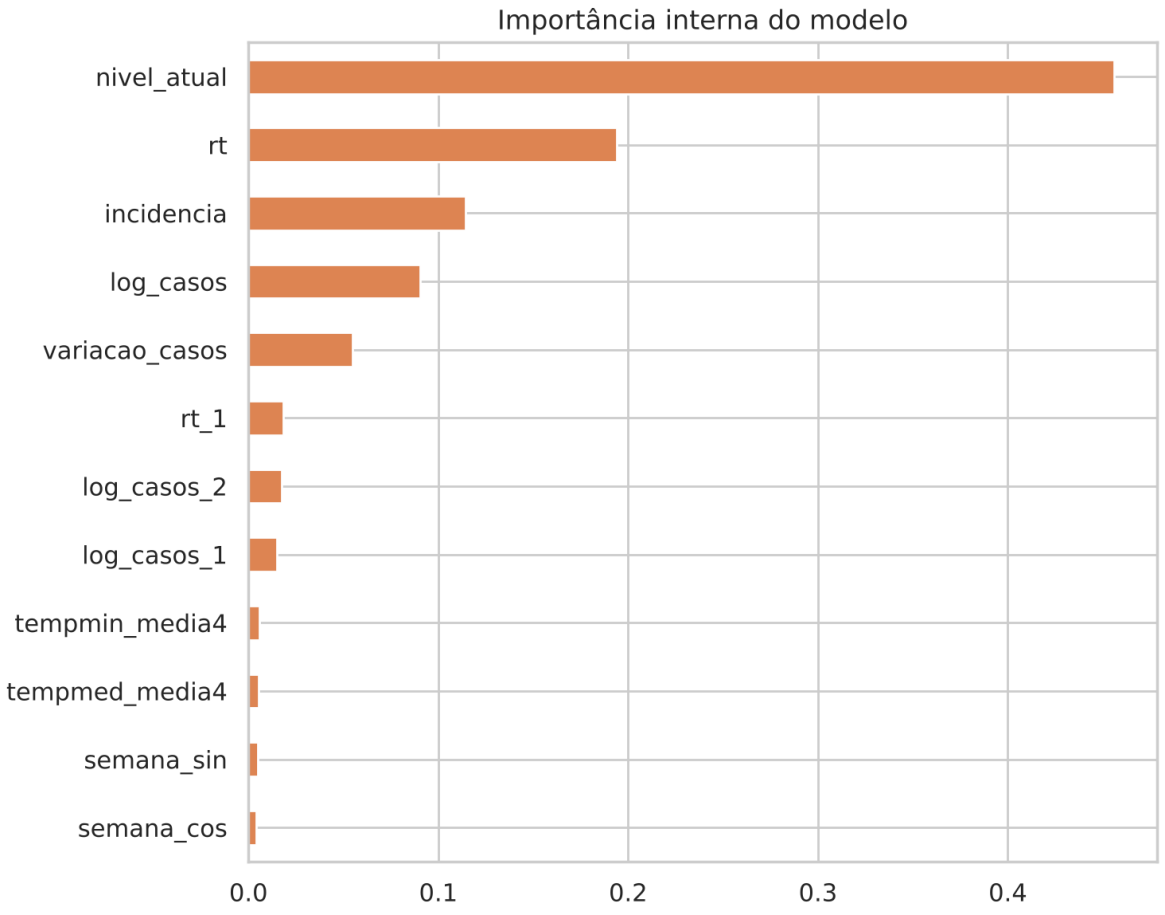




Viradas de nível no teste: persistência acerta 0 de 12, Random Forest 2, Regressão Logística 4 (com mais alarmes falsos)

Importância das variáveis





Nível atual e Rt lideram. Variação dos casos e clima das últimas 4 semanas ajudam a antecipar as viradas.

Demonstração: começo da epidemia de 2024

Semana	Nível atual	Rt	Prob. risco alto	Previsto	Real (semana seguinte)
10/12/2023	3	1,07	0,825	ALTO	baixo
17/12/2023	2	0,89	0,169	baixo	baixo
24/12/2023	2	1,05	0,180	baixo	baixo
31/12/2023	**2**	**2,54**	**0,759**	**ALTO**	**ALTO**
07/01/2024	4	2,24	0,970	ALTO	ALTO

Em 31/12/2023 o nível ainda era amarelo, mas o Rt disparou: o modelo avisou o risco alto uma semana antes da persistência.

Aplicação: a mensagem que chega na família

- **Risco da cidade ALTO + quintal OK:** "Quintal seco, ótimo. A dengue está alta na cidade: mantenha a vistoria semanal."
- **Risco ALTO + quintal ATENÇÃO:** "A dengue deve estar alta na próxima semana e choveu no seu quintal. Faça a vistoria hoje, não espere."
- **Quintal em ALERTA:** "Seu potinho está com água há dias: esvazie os recipientes do quintal hoje."
- **Simulação de começo de surto:** numa semana calma real (16/11/2025) a chance era 13%. Com casos +60%, Rt 1,45 e +3 °C, sobe para 81%.

Benefício e limitações

- **Benefício:** a família recebe o aviso mais forte na semana que importa. Os agentes de saúde podem planejar mutirões nas viradas.
- **Limitação:** o risco é da cidade inteira, não do bairro.
- **Limitação:** o risco muda devagar, então boa parte do acerto vem da situação atual. O modelo ainda perde várias viradas.
- **Limitação:** poucos anos de surto forte no treino, e 2024 foi fora do padrão. Os dados chegam com atraso de notificação.
- **Evoluções:** previsão do tempo, dados dos aparelhos por bairro e retreino mensal.

Relação com os ODS

- **ODS 3 - Saúde e bem-estar:** agir antes do pico reduz casos e mortes por dengue.
- **ODS 11 - Cidades e comunidades sustentáveis:** prevenção no bairro, com famílias, agentes e prefeitura.
- **ODS 13 - Ação contra a mudança do clima:** o calor e a chuva estão nos dados e no modelo.
- **Código:** github.com/matheusrebelo04-maker/alerta-criadouro (pasta ml)